

# Symulacja: Centralne Twierdzenie Graniczne

Wojciech Łoboda

## 1. Wstęp

W ramach projektu przeprowadzona została symulacja w której dla zadanej liczności próby statystycznej, empirycznie szacowane jest pewne prawdopodobieństwo z wykorzystaniem centralnego twierdzenia granicznego Lindeberga-Lévy'ego, które mówi że dla ciągu niezależnych zmiennych losowych o tym samym rozkładzie ze skończoną średnią  $m$  i wariancją  $\sigma^2 > 0$ , ciąg  $Z_n$  jest zbieżny według dystrybucyjności do zmiennej losowej o standardowym rozkładzie normalnym. Projekt został wykonany w języku R, przy pomocy biblioteki *shiny*.

$$Z_n = \frac{\bar{X} - m}{\frac{\sigma}{\sqrt{n}}}$$

## 2. Zestaw danych

Do przeprowadzenia symulacji wybrany został zestaw danych składający się z informacji z portalu IMDB o 1000 filmach które miały premiery między 2006 a 2016 rokiem wraz z ich oceną.

	Title	Director	Year	Rating
1	Guardians of the Galaxy	James Gunn	2014	8.1
2	Prometheus	Ridley Scott	2012	7.0
3	Split	M. Night Shyamalan	2016	7.3
4	Sing	Christophe Lourdelet	2016	7.2
5	Suicide Squad	David Ayer	2016	6.2


Importowanie danych:

```
movies <- read.csv(file = 'dataset/IMDB-Movie-Data.csv')[, c('Title', 'Director', 'Year', 'Rating')]
```

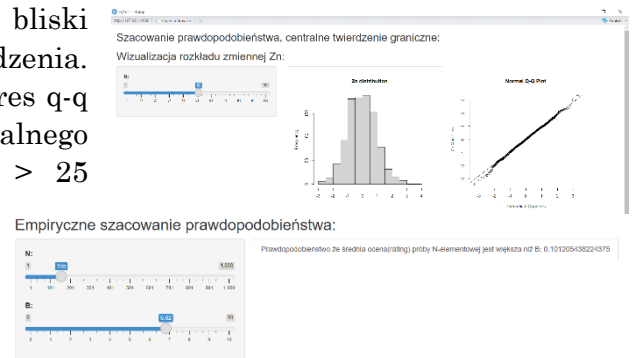
## 3. Działanie programu

Rozpatrywaną zmienną losową  $X_n$  będzie ocena filmu (rating). A wyznaczone prawdopodobieństwo określa szanse na to że średnia ocena filmów w  $n$ -elementowej próbie będzie większa niż podana liczba. Rozkład  $X_n$  nie jest znany ale zmienna posiada średnią  $m = 6.7232$  oraz odchylenie standardowe  $\sigma = 0.9454$ .

Pierwszy suwak pozwala na wybranie  $N$  (rozmiaru próby) dla którego pokazane będzie przybliżony rozkład zmiennej  $Z_n$ . Dla coraz większych  $n$  można zobaczyć że rozkład jest bliski rozkładowi standardowemu zgodnie z treścią twierdzenia. Wskazują na to dwa wykresy: histogram i oraz wykres q-q służący tutaj do porównania rozkładu normalnego standardowego z rozkładem zmiennej  $Z_n$ , dla  $n > 25$  wartości znajdują się prawie w całości na linii co wskazuje na to że rozkłady są sobie równe.



Dwa kolejne suwaki pozwalają na wybranie  $N$  i  $B$  do empirycznego szacowania prawdopodobieństwa że w próbie o liczności  $N$  średnia ocen filmów będzie większa niż  $B$ , prawdopodobieństwo wyświetlane jest obok.



N \ B	6,3	6,75	7,0
30	0,9928	0,4383	0,0544
50	0,9992	0,4205	0,0192
70	0,9999	0,4062	0,0071

Wartości  $P(X_{sr} \geq B)$

Zgodnie z oczekiwaniami dla  $B = 6,3$  (mniejszego od wartości oczekiwanej) dla coraz większej próby prawdopodobieństwo że średnia będzie większa rośnie, jednak dla  $B$  większych można efekt jest odwrotny, dla  $B = 7,0$  prawdopodobieństwo większej średniej jest minimalne a dla większych  $n$  prawie znikome.